Relatório Consolidado de Benchmarking – Iniciação Científica

Escalabilidade de Hardware vs. Estruturação Física de Dados (DataOps) no Apache Druid

Projeto DataOps / UNIFEI

12 de março de 2026

---

1. Resumo Executivo da Metodologia

Este documento unifica as seis etapas da pesquisa experimental. O objetivo foi quantificar o impacto da paralelização de hardware (2, 4 e 6 núcleos) em contraponto à aplicação de técnicas de *DataOps* (neste caso, a compactação de dados). A base total compreende mais de 3,1 milhões de registros de focos de calor, inicialmente distribuídos em 6.518 arquivos minúsculos (*Tiny Segments*) e, posteriormente, compactados com granularidade anual (*CompactYear*).

2. Fase 1: O Gargalo da Fragmentação (Cenários 1 a 3)

No **Cenário 1** (2 Núcleos, Fragmentado), o sistema operou sob estrangulamento severo de I/O. As latências de varredura plena superaram a marca crítica dos **4666.32 ms**. Registrou-se o início do Paradoxo do Cache, onde a consulta territorial obteve otimização negativa (**-0.76%**).

Com o **Cenário 2** (4 Núcleos) e **Cenário 3** (6 Núcleos), o incremento bruto de processador atenuou a latência. A Alta Cardinalidade caiu para **1756.32 ms** no ápice do hospedeiro. Contudo, a ineficiência do cache colunar persistiu (**-12.47%** em C3), provando que injetar processador não resolve o gargalo de roteamento lógico em memória RAM causado pela fragmentação.

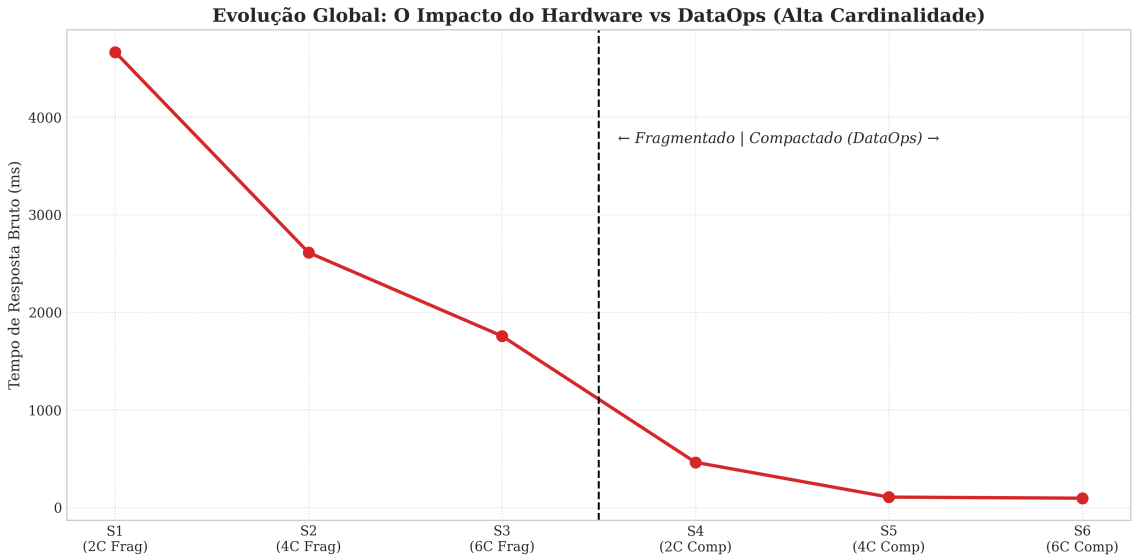

Figura 1 – A evolução contundente do tempo de resposta provando a superioridade do DataOps sobre o provisonamento de hardware bruto.

3. Fase 2: O Triunfo do DataOps (Cenários 4 a 6)

A virada arquitetural ocorreu no **Cenário 4**, onde o hardware foi rebaixado para 2 núcleos, mas a base foi consolidada via *Compaction*. A latência de Alta Cardinalidade despencou de forma colossal para **461.91 ms**. O cache RAM ressuscitou, atingindo picos de eficiência de **87.76%**.

Ao aplicar paralelismo sobre a base otimizada no **Cenário 5** (4 núcleos) e **Cenário 6** (6 núcleos), o sistema atingiu seu limite fisiológico. No Cenário 6, a Alta Cardinalidade quebrou a barreira dos 100ms, registrando **94.45 ms**.

O fenômeno mais intrigante, o *"Too Fast to Cache"*, atingiu seu extremo no Cenário 6. Consultas complexas demoraram apenas **18.91 ms** no processamento bruto, tornando-se mais rápidas que a própria memória RAM (**27.90 ms**), o que gerou um ganho matemático negativo de **-47.54%**.

4. Conclusão da Pesquisa

A bateria de testes comprova matematicamente a hipótese central: em bancos de dados analíticos colunares orientados a *Big Data* (OLAP), a engenharia física dos dados supera amplamente o provisionamento irrestrito de CPU. A compactação reduziu o tempo de resposta em mais de 40 vezes, enquanto a adição de núcleos entregou ganhos secundários de refino.